




LATRACE AI 商业计划书

面向 AI Agent 的全模态长期记忆基础设施

一句话定位：LATRACE 让 AI Agent 拥有可追踪、可解释、跨视频/音频/文本的长期记忆。

字段	内容	字段	内容
项目名称	LATRACE AI	当前阶段	完整产品化已形成
关键成绩	LongMemEval 全球双榜单 SOTA；视觉记忆 benchmark 表现优秀	联系方式	17512593659
下一阶段	服务器承载力、运营、营销、统一多模态隐空间记忆研发	日期	2026年5月

一、执行摘要

LATRACE AI 是面向下一代 AI Agent 的全模态记忆引擎。它把视频、音频、文本统一编译进同一张时序知识图谱与隐空间状态体系，使 Agent 不再依赖短期上下文窗口或文本摘要，而是能够长期追踪实体、事件、关系、状态变化与证据链。

项目已经从技术验证进入完整产品化阶段：核心服务、媒体编译管线、图谱/向量双写、Agent 工具层和本地部署链路均已形成。下一阶段重点是扩大服务器承载力、运营获客、市场转化，并继续研发统一多模态隐空间记忆。

- 核心定位：AI Agent / AI 角色 / 陪伴式产品的长期记忆基础设施。
- 验证结果：在国际长期记忆 benchmark LongMemEval 上取得全球双榜单 SOTA，并在视觉记忆 benchmark 上取得优秀结果。
- 产品形态：开源引擎 + API 服务 + Agentic Memory Tools，可支持 SaaS、私有化部署和开发者生态三类路径。

二、痛点与机会

当前大模型产品的“记忆”大多停留在文本片段检索：用户交互被压缩成摘要，视频被转写成文字描述，音频被转成 ASR 文本，再通过 RAG 塞回 Prompt。这一路径会丢失视觉细节、说话人身份、语气、实体状态变化和时间演化关系。

随着 AI 伴侣、AI 角色、教育陪练、个人助理、具身机器人和企业 Agent 的发展，长期记忆会成为模型能力之外的基础设施。谁能稳定保存、更新、查询和解释“用户与世界的状态”，谁就能决定 Agent 是否具备真实连续性。

- 传统 RAG 解决“查文本”，但难以解决“持续记住一个人/一段关系/一个状态”。
- 多模态交互正在成为主流，记忆系统必须原理解视频、语音和文本，而不是把所有输入先压成文本。
- Agent 需要可调用、可追溯、可解释的结构化记忆工具，而不是不可控的 prompt stuffing。

三、产品方案

LATRACE 的产品核心是“Video / Audio / Text in, One Graph out”。视频、语音、文本分别经过媒体编译器和语义抽取链路，形成实体、事件、状态、关系、时间线和证据，再写入统一的 Typed Knowledge Graph，并通过向量检索、图遍历和融合重排服务给上层 Agent 使用。

开发者既可以通过 Retrieval API 快速接入，也可以使用 ADK Tools 让 Agent 主动查询 entity_profile、entity_status、status_changes、topic_timeline、quotes、relations、explain、time_since、state_time_since 等结构化工具。

能力层	当前形态	对客户价值
多模态输入	视频、音频、文本统一进入记忆管线	用户交互不再被压缩为单一文本摘要
状态记忆	实体状态、关系、时间线、证据链持续更新	Agent 能追踪变化，而不是只复读历史片段
Agent 工具	原生结构化查询工具与 API	上层产品可低成本获得长期记忆能力
部署方式	Docker / API / 私有化部署	适配开源开发者、企业客户和垂直应用团队

四、技术壁垒

LATRACE 与普通 RAG 或文本记忆插件的区别，在于它不是把历史对话切块后检索，而是把多模态信息编译成可演化的结构化状态。技术路线同时覆盖媒体感知、实体对齐、时间建模、图谱写入、向量检索、证据链

追溯和 Agent 工具调用。

- 统一图谱：视频、音频、文本共享一套实体、时间戳、关系和状态体系。
- 图 + 向量双路：同时支持语义召回和关系/时间推理。
- 证据链：每个记忆结论可追溯到来源片段，增强可信度和可解释性。
- 下一代研发方向：统一多模态隐空间记忆，使记忆从结构化图谱进一步升级为连续状态表示。

五、阶段成绩

项目已经形成可运行、可部署、可验证的产品化系统。官网和开源仓库已经将核心产品叙事、接口路径、部署方式、能力比较和路线图对外呈现。

维度	已取得结果	意义
Benchmark	LongMemEval 全球双榜单 SOTA；视觉记忆 benchmark 表现优秀	证明长期记忆与视觉记忆能力具备国际竞争力
产品化	已形成文本/音频/视频到统一图谱的主线能力	具备从研发走向客户试用和服务化的基础
工程化	API、Agent 工具、Docker 部署、图谱/向量存储链路已成型	降低开发者接入和企业验证成本
品牌表达	官网强调“记忆在隐空间”与“不是另一个 RAG”	有清晰的差异化叙事，利于融资和市场传播

六、市场与客户路径

第一阶段聚焦对长期记忆最敏感、最愿意试用新基础设施的场景：AI 角色/伴侣、个人助理、教育陪练、内容创作 Agent 和开发者工具。中期可扩展到企业知识 Agent、会议/销售/客服记忆、具身机器人和多设备个人智能体。

- 开发者入口：开源仓库和一键部署，积累技术用户与真实场景反馈。
- 应用入口：面向 AI 角色、陪伴、教育等场景提供 API 和托管记忆服务。
- 企业入口：为重视隐私、可解释性和多模态数据沉淀的客户 提供私有化部署。

七、商业模式

LATRACE 适合采用“开源内核 + 托管服务 + 私有化部署”的商业结构。开源部分降低开发者试用门槛，托管 API 承接中小团队付费，私有化部署承接高价值企业客户。

模式	收费逻辑	适用客户
托管 API / SaaS	按调用量、存储量、活跃用户或租户计费	AI 应用团队、Agent 产品、早期创业公司
私有化部署	部署费 + 年服务费 + 定制集成	企业知识 Agent、教育/客服/销售场景
开发者生态	开源免费，商业能力/云服务付费	研究者、独立开发者、生态合作伙伴

八、资金使用计划

本轮 Delta Empower 资助将用于把已经产品化的系统推向更稳定的服务化和早期市场验证。资金用途围绕承载力、运营、营销和下一代研发投入。

用途	建议比例	说明
服务器与云资源	35%	扩展 API、图谱、向量库和媒体编译服务承载力，支持更多试用和评测任务
运营与客户试用	20%	搭建早期试用流程、反馈闭环、部署文档和支持体系
市场与品牌传播	20%	官网、案例、开源传播、开发者活动和垂直场景材料
统一多模态隐空间记忆研发	25%	推进连续状态记忆、跨模态状态对齐、Agent 工具增强和评测体系

九、团队

团队由算法、AI Infra、数学和数据科学背景成员构成，具备从研究验证、系统工程到产品表达的组合能力。现阶段以小团队快速迭代为主，后续将补齐前端增长、开发者运营和企业交付能力。

成员	背景	职责
赵翔	浙江大学博士在读，优化算法 / AI Infra / Memory Infra	创始人及项目负责人，负责总体方向、核心系统、产品化和融资推进
蒙略	中国科学技术大学少年班学院数学与应用数学；数学科学学院应用数学硕士	负责数学建模、记忆机制、算法验证和研究推进
李正楠	香港中文大学（深圳）数据科学硕士在读	负责数据科学、评测、实验分析和产品验证

十、十二个月路线图

路线图遵循“服务稳定性与市场验证优先，同时推进长期技术壁垒”的节奏。短期目标是让更多真实开发者和应用团队用起来，中期目标是形成可收费的托管服务和私有化部署能力，长期目标是成为 AI Agent 的状态基础设施。

阶段	目标	关键交付
0-3个月	服务化与承载力提升	服务器扩容、监控、部署文档、试用客户接入、官网和案例完善
3-6个月	早期商业验证	API 计费雏形、垂直场景模板、开发者社区、私有化试点
6-12个月	统一隐空间记忆升级	Belief State Engine、跨模态状态对齐、Benchmark 扩展和企业级能力